


Contoh 6.5 (Return harian 500 Indeks Standard dan Poor). Dataset runtun waktu SP500dailyreturns adalah indeks SP500 daily return dari 5 Jan 1999 hingga 12 Des 2018. Plot waktunya ditunjukkan pada Gambar 6.18. Runtun return stasioner dapat dilihat pada plot ACF dan PACF di Gambar 6.19 dan hasil pengujian KPSS. Namun hal tersebut bukan white noise karena gagal dalam uji Ljung-Box yang dapat dilihat pada plot p -value yang ditunjukkan di Gambar 6.20. Oleh karena itu, kita harus membangun model ARMA yang memadai. Pada titik ini, kita menemukan bahwa sulit untuk menentukan orde (p, q) dari model ARMA yang sesuai dengan runtun return. Setelah puluhan percobaan, kita pilih orde $(p, q) = (15, 2)$ dan diperoleh estimasi model ARMA(15, 2) dengan fungsi SARIMAX(). Estimasi model ARMA(15, 2) ditunjukkan pada tabel pertama SARIMAX Results di bawah ini. Saat mengamatinya dengan cermat, kita menemukan bahwa estimasi beberapa parameter tidak signifikan secara statistik. Jadi kita menyempurnakan model dengan memperbaiki parameter $\text{intercept} = \text{ar.L8} = \text{ar.L10} = \text{ar.L14} = 0$. Kita akhirnya memiliki model ARMA yang dihasilkan (model mean) yang ditunjukkan pada tabel kedua SARIMAX Results di bawah ini. Ketika membandingkan AIC, BIC, dan HQIC untuk model estimasi kedua dengan AIC, BIC, dan HQIC untuk model estimasi pertama, maka model kedua lebih baik daripada model pertama. Selanjutnya, model ARMA yang dihasilkan sesuai karena residualnya lulus uji Ljung-Box, lihat pada Gambar 6.21 dan 6.22. Pada saat yang sama, kita menemukan bahwa runtun residual memiliki efek ARCH dari Gambar 6.23.


Model GARCH (volatilitas) yang sesuai untuk runtun return selanjutnya dibangun menggunakan residual model mean. Kita menemukan bahwa orde model GARCH (volatilitas) harus dipilih sebagai $(p, q) = (2, 2)$. Model volatilitas yang dihasilkan ditunjukkan pada tabel Zero Mean - GARCH Model Results di bawah ini. Kita melihat bahwa model volatilitas yang sesuai dari Gambar 6.24, 6.25, 6.26, dan 6.27, yaitu residual model GARCH sudah tidak berkorelasi dan tidak memiliki efek ARCH lagi. Plot QQ yang ditunjukkan pada Gambar 6.28 menunjukkan bahwa left tails-nya berdis-

tribusi empiris dari residual lebih berat dari salah satu distribusi normal. Kita dapat menjalankan perintah Python berikut untuk dapat memperoleh semua hasil dan plot dalam contoh.




Gambar 6.18: Plot runtun waktu dari SP500 return dalam Contoh 6.5

```
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
from PythonTsa.plot_acf_pacf import acf_pacf_fig
from PythonTsa.LjungBoxtest import plot_LB_pvalue
from arch import arch_model
from statsmodels.graphics.gofplots import qqplot
# Membaca data return S&P 500
ret = pd.read_csv('SP500dailyreturns.csv', header=None,
                  names=['returns'])
# Plot data return
ret.plot(title="Return Harian S&P 500")
plt.xlabel("Waktu")
plt.ylabel("Return")
plt.grid()
plt.show()
# Plot ACF dan PACF untuk return
acf_pacf_fig(ret, both=True, lag=40)
plt.suptitle("ACF dan PACF Return S&P 500", y=0.95)
plt.show()
# Uji KPSS untuk stasionaritas
print("Hasil Uji KPSS:")
print(sm.tsa.kpss(ret, regression='c', nlags='auto'))
# Uji Ljung-Box untuk return
plot_LB_pvalue(ret, noestimatedcoef=0, nlags=30)
plt.suptitle("P-Value Ljung-Box untuk Return S&P 500", y=0.98)
plt.show()
```



Gambar 6.19: ACF dan PACF dari SP500 return dalam Contoh 6.5



Gambar 6.20: Plot nilai p uji Ljung-Box dari return SP500 Contoh 6.5

Hasil Uji KPSS:

(0.1501534339907281, 0.1, 22, {'10%': 0.347, '5%': 0.463, '2.5%': 0.574, '1%': 0.739})

InterpolationWarning: The test statistic is outside of the range of p-values available in the look-up table.

```
# Estimasi model ARMA(15,2) dengan intercept
arma152 = sm.tsa.SARIMAX(ret, order=(15, 0, 2), trend='c').fit()
print(arma152.summary())
```

6.2 Model Heteroskedastisitas

SARIMAX Results

```

Dep. Variable: returns    No. Observations:    5030
Model: SARIMAX(15, 0, 2)  Log Likelihood      -8009.710
Date: Mon, 17 Feb 2025    AIC                  16057.420
Time: 17:37:04           BIC                  16181.360
Sample: 0                HQIC                 16100.846
      - 5030
      opg

```

Covariance Type:

	coef	std err	z	P> z	[0.025	0.975]
intercept	0.0575	0.041	1.414	0.157	-0.022	0.137
ar.L1	-0.5845	0.061	-9.594	0.000	-0.704	-0.465
ar.L2	-0.7568	0.059	-12.890	0.000	-0.872	-0.642
ar.L3	-0.0750	0.013	-5.799	0.000	-0.100	-0.050
ar.L4	-0.0599	0.011	-5.241	0.000	-0.082	-0.038
ar.L5	-0.0590	0.011	-5.519	0.000	-0.080	-0.038
ar.L6	-0.0494	0.012	-4.227	0.000	-0.072	-0.026
ar.L7	-0.0688	0.012	-5.510	0.000	-0.093	-0.044
ar.L8	-0.0169	0.012	-1.436	0.151	-0.040	0.006
ar.L9	-0.0339	0.012	-2.749	0.006	-0.058	-0.010
ar.L10	0.0125	0.012	1.040	0.298	-0.011	0.036
ar.L11	-0.0191	0.012	-1.556	0.120	-0.043	0.005
ar.L12	0.0419	0.012	3.590	0.000	0.019	0.065
ar.L13	0.0201	0.013	1.548	0.122	-0.005	0.046
ar.L14	0.0001	0.013	0.010	0.992	-0.025	0.026
ar.L15	-0.0538	0.011	-5.114	0.000	-0.074	-0.033
ma.L1	0.5111	0.060	8.483	0.000	0.393	0.629
ma.L2	0.6688	0.057	11.704	0.000	0.557	0.781
sigma2	1.4146	0.015	95.337	0.000	1.385	1.444

```

Ljung-Box (L1) (Q):    0.00  Jarque-Bera (JB):    10575.17
Prob(Q):               1.00  Prob(JB):              0.00
Heteroskedasticity (H): 0.46  Skew:              -0.22
Prob(H) (two-sided):   0.00  Kurtosis:          10.09

```

```

# Estimasi model ARMA dengan parameter yang lebih spars
arma122 = sm.tsa.SARIMAX(ret, order=[1, 1, 1, 1, 1, 1, 0, 1, 0,
1, 1, 1, 0, 1], 0, 2), trend='n').fit()
print(arma122.summary())

```

SARIMAX Results

```

Dep. Variable: returns    No. Observations:    5030
Model: SARIMAX([1, 2, 3, 4, 5, 6, 7, 9, 11, 12, 13, 15], 0, 2)
Log Likelihood      -8011.944

```

202

Date: Mon, 17 Feb 2025 17:37:09
Time: 0
Sample: - 5030
opg

AIC 16053.888
BIC 16151.736
HQIC 16088.172


Covariance Type:

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	-0.5797	0.050	-11.513	0.000	-0.678	-0.481
ar.L2	-0.7495	0.053	-14.270	0.000	-0.852	-0.647
ar.L3	-0.0728	0.012	-6.058	0.000	-0.096	-0.049
ar.L4	-0.0580	0.011	-5.305	0.000	-0.079	-0.037
ar.L5	-0.0574	0.010	-5.589	0.000	-0.078	-0.037
ar.L6	-0.0378	0.010	-3.846	0.000	-0.057	-0.019
ar.L7	-0.0542	0.010	-5.590	0.000	-0.073	-0.035
ar.L9	-0.0319	0.008	-3.752	0.000	-0.049	-0.015
ar.L11	-0.0302	0.010	-3.086	0.002	-0.049	-0.011
ar.L12	0.0335	0.010	3.454	0.001	0.014	0.052
ar.L13	0.0209	0.010	2.151	0.031	0.002	0.040
ar.L15	-0.0537	0.008	-6.504	0.000	-0.070	-0.038
ma.L1	0.5073	0.050	10.231	0.000	0.410	0.604
ma.L2	0.6631	0.052	12.770	0.000	0.561	0.765
sigma2	1.4159	0.014	97.777	0.000	1.387	1.444


Ljung-Box (L1) (Q): 0.00 Jarque-Bera (JB): 10524.97
Prob(Q): 0.96 Prob(JB): 0.00
Heteroskedasticity (H): 0.46 Skew: -0.22
Prob(H) (two-sided): 0.00 Kurtosis: 10.07

```
# Residual dari model ARMA(1,2,2)
xresid = armal22.resid
# ACF dan PACF dari residual
acf_pacf_fig(xresid, both=True, lag=40)
plt.suptitle("ACF dan PACF Residual Model ARMA", y=0.95)
plt.show()
# Uji Ljung-Box untuk residual ARMA
plot_LB_pvalue(xresid, noestimatedcoef=14, nolags=30)
plt.suptitle("P-Value Ljung-Box untuk Residual ARMA", y=0.98)
plt.show()
# ACF dari kuadrat residual
acf_pacf_fig(xresid**2, lag=40)
plt.suptitle("ACF dari Kuadrat Residual ARMA", y=0.95)
plt.show()
# Estimasi Model GARCH(2,2) mean nol
garch = arch_model(xresid, p=2, q=2, mean='Zero')
garchmod = garch.fit(dispatch='off')
print(garchmod.summary())
```

ACF dan PACF Residual Model ARMA




Gambar 6.21: ACF PACF residual ARMA dari return SP500 dalam Contoh 6.5

p-value Ljung-Box untuk Residual ARMA
p-values for Ljung-Box statistics

Gambar 6.22: Plot p-value untuk uji L-B residual ARMA dari return SP500

ACF dari Kuadrat Residual ARMA



Gambar 6.23: Plot ACF residual ARMA kuadrat dari return SP500

Zero Mean - GARCH Model Results

```

=====
Dep. Variable:          None    R-squared:          0.000
Mean Model:            Zero Mean  Adj. R-squared:     0.000
Vol Model:             GARCH      Log-Likelihood:    -6941.21
Distribution:          Normal     AIC:               13892.4
Method:               Maximum Likelihood  BIC:               13925.0
                                           No. Observations:  5030
Date:                 Mon, Feb 17 2025    Df Residuals:      5030
Time:                 17:37:09           Df Model:           0
                                           Volatility Model
=====

```

```

=====
              coef      std err      t      P>|t|      95.0% Conf. Int.
-----
omega      0.0301  8.450e-03  3.558  3.738e-04  [1.350e-02, 4.662e-02]
alpha[1]   0.0607  2.217e-02  2.740  6.141e-03  [1.730e-02, 0.104]
alpha[2]   0.1090  2.058e-02  5.298  1.171e-07  [6.871e-02, 0.149]
beta[1]    0.2236   0.300  0.745   0.456   [ -0.365, 0.812]
beta[2]    0.5841   0.279  2.095  3.615e-02  [3.772e-02, 1.131]
=====


```

Covariance estimator: robust


```

# Standardized Residual dari Model GARCH
garchresid = garchmod.std_resid
# ACF dan PACF dari standardized residual
acf_pacf_fig(garchresid, both=True, lag=40)
plt.suptitle("ACF dan PACF Residual GARCH(2,2)", y=0.95)
plt.show()
# Uji Ljung-Box untuk residual GARCH
plot_LB_pvalue(garchresid, noestimatedcoef=0, nolags=30)
plt.suptitle("P-Value Ljung-Box untuk Residual GARCH(2,2)", y=0.98)
plt.show()
# ACF dan PACF dari kuadrat standardized residual
acf_pacf_fig(garchresid**2, both=True, lag=40)
plt.suptitle("ACF dan PACF Kuadrat Residual GARCH(2,2)", y=0.95)
plt.show()
# Uji Ljung-Box untuk kuadrat residual standardized
plot_LB_pvalue(garchresid**2, noestimatedcoef=0, nolags=30)
plt.suptitle("P-Value Ljung-Box untuk Kuadrat Residual GARCH(2,2)",
y=0.98)
plt.show()
# QQ-Plot Residual GARCH
qqplot(garchresid, line='q', fit=True)
plt.title("QQ-Plot Residual GARCH(2,2)")
plt.show()

```



Gambar 6.27: Plot p -value uji L-B residual GARCH kuadrat dari return SP500



Gambar 6.28: Plot QQ dari residual GARCH iidN(0, 1) dari return SP500

6.3 Perluasan Model

Model GARCH mampu menangkap beberapa karakteristik penting dari runtun waktu keuangan. Namun, model ini masih memiliki keterbatasan dalam merepresentasikan seluruh dinamika pasar keuangan. Salah satunya adalah ketidakmampuannya untuk menangkap asimetri dalam volatilitas, yaitu perbedaan reaksi pasar terhadap kabar baik dan kabar buruk. Dalam kenyataannya, volatilitas sering kali meningkat lebih tajam setelah kabar buruk dibandingkan dengan kabar baik yang setara.

Untuk mengatasi keterbatasan ini, berbagai perluasan dari model GARCH telah dikembangkan. Dua di antaranya yang paling populer adalah model Exponential GARCH (EGARCH) dan model Threshold GARCH (TGARCH). Model EGARCH, yang diperkenalkan oleh D. B. Nelson (1991), memperkenalkan pendekatan logaritmik untuk varians kondisi guna mengakomodasi efek asimetris dalam volatilitas. Se-